Universidad Interamericana PR – Bayamón

Ciencia de Datos

Proyecto -1

Machine Learning para clasificación de etapas de sueño y detección de apnea

Resume del proyecto

- Uso exclusivo de EEG de un solo canal (frontal o central estándar).
- Aplicación y comparación de tres familias de modelos tradicionales: SVM-RBF, Random Forest/baging y Boosting tipo AdaBoost/XGBoost/Gradient Boosting.
- Validación subject-wise y experimentos cross-dataset para medir robustez y generalización.
- Comparación crítica con baselines publicados y propuesta de una mejora metodológica.

Contexto del proyecto

La Apnea Obstructiva del Sueño (AOS) produce interrupciones repetidas de la respiración durante el sueño y su diagnóstico clínico se apoya en estudios Polisomnografía (PSG). En años recientes ha crecido el interés por sistemas automáticos más simples que empleen señales de Electroencelografia (EEG) monocanal (1 solo canal) para clasificar etapas de sueño y detectar apnea, con el fin de reducir complejidad instrumental y facilitar escenarios de monitoreo simplificado.

Objetivo general

Aplicar tres algoritmos tradicionales de machine learning: SVM con kernel (busque el mejor), Random Forest y variantes tipo boosting — para dos tareas: (1) clasificación de etapas de sueño y (2) detección de apnea usando únicamente EEG de un solo canal, con comparación frente a trabajos reconocidos (baselines) publicados sobre los mismos conjuntos de datos.

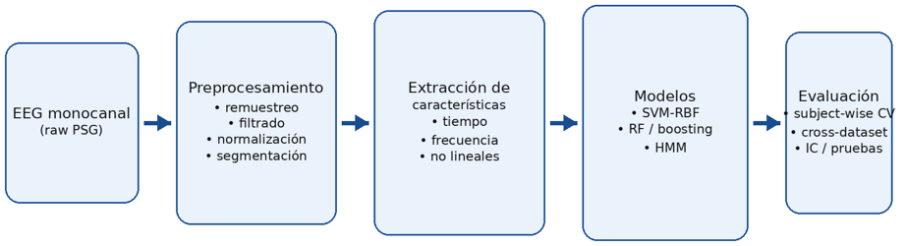

Figura 1. Flujo experimental sugerido para el proyecto

Objetivos específicos

- Construir pipelines reproducibles de preprocesamiento, extracción de características, entrenamiento y evaluación.
- Implementar al menos tres familias de modelos: SVM-RBF, Random Forest, y una variante boosting (o ensamblada)
- Evaluar desempeño dentro de cada dataset mediante validación subject-wise k-fold.
- Evaluar generalización cross-dataset entrenando en una o varias bases y probando en otra.
- Comparar resultados propios con 6–10 referencias científicas relevantes y con al menos 3 baselines bien documentados.
- Analizar críticamente las limitaciones observadas y proponer un nuevo método que pudiera superar el baseline obtenido.

Modelos a utilizar

Modelo	Sugerencias mínimas	Observación
SVM (RBF)	Buscar C, gamma, class_weight y estrategia multiclase	Especialmente útil con features bien normalizados y seleccionados
Random Forest / bagging	n_estimators, max_depth, max_features, min_samples_leaf	Debe incluir importancia de features
Boosting tipo AdaBoost/XGBoost/Gradient Boosting	Comparar contra RF puro con mismo protocolo	Muy recomendado para clases desbalanceadas
HMM	Probar HMM directo sobre features y/o HMM como suavizado de secuencias	La matriz de transición debe analizarse e interpretarse

Conjuntos de datos

El proyecto utilizará registros públicos de sueño restringidos a un único canal EEG (frontal o central estándar), siguiendo protocolos por sujeto para evitar fuga de información.

Dataset	Uso esperado	Etiquetas	Tener en cuenta:
Sleep-EDF Expanded	Base principal para desarrollo y baseline	W / N1 / N2 / N3 / REM; apnea si la anotación está disponible en la partición usada	Documentar canal elegido, mapeo de etiquetas y limpieza
MIT-BIH PSG	Base complementaria para apnea/sueño	Etiqueta Apnea/no-apnea por ventana; estadios si existen en la partición seleccionada	Explicar claramente cómo se sincronizan anotaciones con ventanas
SHHS	Base amplia para generalización	Apnea/no-apnea, severidad global y staging según disponibilidad	Ideal para estudiar cambio de dominio y cohortes heterogéneas
St. Vincent's University Hospital	Base clínica adicional	Apnea/no-apnea y/o staging según el subconjunto trabajado	Especificar partición, acceso y canal equivalente al estándar
ISRUC-Sleep	Base complementaria para clasificación etapas(staging)	W / N1 / N2 / N3 / REM	Útil para contrastar con Sleep-EDF y estudiar generalización

Los datasets son públicos y los puede bajar de Internet crudos(raw) o ya listos para trabajar. Por ejemplo, para datasets públicos de EEG puede utilizar:

- **Kaggle + Claude/ChatGPT** — Describes el dataset (Sleep-EDF, ISRUC, SHHS) y generas el pipeline de carga y preprocesamiento.
- **HuggingFace** — Busca datasets y modelos pre-entrenados en EEG/BCI que puedes usar como baseline o fine-tuning.

Diseño experimental

1. Protocolos subject-wise (Figura-2): cada sujeto debe aparecer exclusivamente en entrenamiento/validación o en prueba.
2. Validación k-fold dentro de cada dataset, reportando media y desviación estándar.
3. Experimentos cross-dataset: entrenar en uno o varios datasets y probar en otro, sin ajustar hiperparámetros sobre el conjunto de prueba destino.
4. Todas las etapas del pipeline que aprendan parámetros (normalización, selección de features, balanceo, calibración) deben ajustarse únicamente con el fold de entrenamiento.
5. Se debe fijar semilla aleatoria y registrar configuración para reproducibilidad.

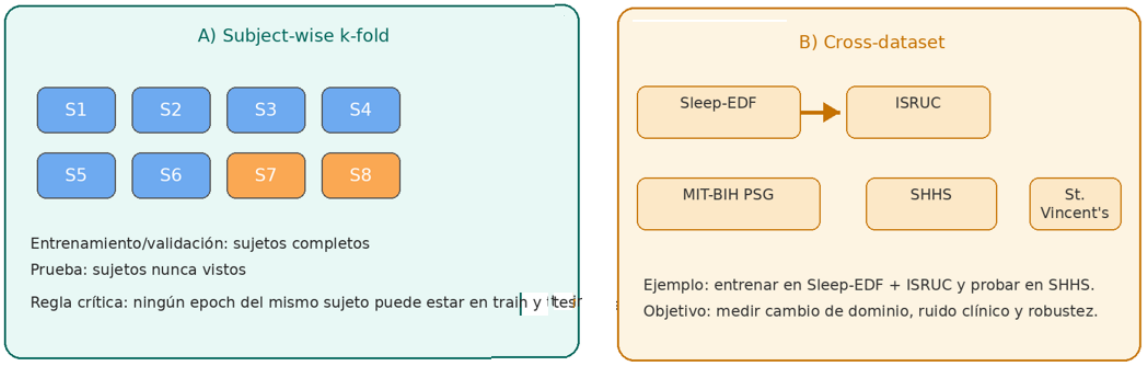

Figura 2. Los dos protocolos mínimos exigidos por el proyecto.

Estructura del informe

1. Portada (curso, nombres, fecha).
2. Resumen / Abstract de 150–250 palabras.
3. Introducción y motivación.
4. Revisión de literatura: al menos 6–10 referencias científicas relevantes.
    - Desarrollar la seccion: Revisión Literatura
5. Datasets y preprocesamiento
    - Desarrollar la seccion: Preprocesamiento y extracción de características
6. Modelos base: arquitectura, hiperparámetros, protocolo CV y resultados de los modelos baseline.
7. Resultados obtenidos: Tener en cuenta las metricas mencionadas en la seccion: “Métricas y análisis estadístico”. Mostrar tablas y figuras comparando metodo implementado con mejor método baseline y referencias externas. Ejemplo de tablas a mostrar:

Tabla-1: Métricas promedio (de los folds)

Metrica	Modelo 1	Modelo 2	Modelo 3
accuracy			
. . .	. . .	. . .	. . .

Tabla-2: F1 por clases (promedio de todos los folds)

Clase	Modelo-1	Modelo-2	Modelo-3
N1			
N2			
N3			
REM			
W			

8. Análisis y discusión.
   - Responder las preguntas en sección: “Preguntas a responder”
9. Propuesta de mejora con nuevo método: teoría, formulación y pseudocódigo.
   - Desarrollar la sección: “ Propuesta de mejora”
10. Conclusiones y trabajo futuro.
11. Referencias en formato IEEE.
12. Apéndice opcional: comandos de ejecución.

Revisión de Literatura

Cada equipo debe presentar una revisión de literatura breve pero crítica con dos subobjetivos:

a) Preprocesamiento: Identificar métodos de preprocesamiento y extracción de features que hayan sido influyentes para SVM, RF/boosting y HMM en EEG de sueño. Deben justificar qué señales filtran, cómo segmentan, cómo normalizan y qué rasgos calculan.

b) Comparaciones / baselines: Identificar modelos baseline publicados sobre los mismos datasets o sobre variantes muy cercanas. Deben explicar por qué el baseline es comparable, qué protocolo empleó y qué métricas reportó.

Herramientas IA clave:

- **Elicit.org** — El más poderoso para investigación. Le describes tu problema en lenguaje natural y extrae papers relevantes, resume sus metodologías, métricas y limitaciones en una tabla comparativa. Filtra por año, citaciones, tipo de estudio.
- **Consensus.app** — Orientado a encontrar consenso científico. Ideal para preguntas como "¿Es el SVM mejor que LSTM para clasificación de EEG?"
- **SciSpace (Typeset.io)** — Lee un paper y tiene un chat lateral que explica cada sección, fórmula y figura. Tiene agentes. Revolucionario para papers densos en matemáticas

Preprocesamiento y extracción de características

Se espera que al menos consideren:

- Segmentación en ventanas consistentes con el etiquetado.
- Filtrado y/o remuestreo apropiado para el canal EEG seleccionado.
- Normalización por sujeto o por registro, documentando el procedimiento.
- Técnica para extracción de features(características)
- Estrategias para desbalance de clases: class weighting, undersampling, oversampling, SMOTE u otras.
- Análisis de artefactos/ruido: cómo se detectan, excluyen o modelan.

Métricas y análisis estadístico

Para apnea/no-apnea: Accuracy, sensibilidad, especificidad y AUC-ROC.; Exactitud en la clasificación de severidad por paciente.

Para estadios de sueño: Accuracy global, macro-F1 y kappa de Cohen.; Análisis por clase con énfasis especial en N1.

Métricas por paciente: Sensibilidad y especificidad para puntos de corte de AHI que el equipo adopte y documente.

Análisis estadístico: Promedio y desviación estándar sobre folds.; Intervalos de confianza mediante bootstrap.; McNemar y comparación de AUC cuando proceda, para contrastar el mejor modelo propio contra un baseline.

Propuesta de mejora

Después de analizar los resultados, cada equipo debe proponer un método nuevo que potencialmente mejore el baseline. Considere: transformers, nuevas representaciones tiempo-frecuencia, adaptación de dominio, ensambles, etc, (explique). No es obligatorio implementarlo completamente, pero sí debe estar claramente formulado y defendido.

a) Descripción teórica del método propuesto. Hacer diagrama
b) Justificación de por qué podría mejorar robustez, generalización o desempeño en clases difíciles.
c) Algoritmo o pseudocódigo.
d) Qué datos adicionales, features, arquitecturas o estrategias requeriría.
e) Cómo se evaluaría de manera justa frente a los modelos ya probados.

La implementación de la propuesta de mejora es un BONO

Preguntas a responder

1. ¿Qué combinación de preprocesamiento + features produjo el mejor resultado y por qué cree que funcionó mejor?
2. ¿Qué tan sensible fue cada modelo al desbalance de clases, especialmente en N1 o en apnea/no-apnea?
3. ¿Qué diferencias observa entre accuracy, macro-F1 y kappa? ¿Algún modelo parece “bueno” solo porque favorece las clases mayoritarias?
4. ¿Qué patrones aparecen en las matrices de confusión? ¿Qué clases se confunden con mayor frecuencia y por qué?
5. ¿El mejor modelo dentro de un dataset también fue el mejor en cross-dataset? Si no, ¿qué indica eso sobre generalización?
6. ¿Qué tanto cambió el rendimiento al pasar de epoch-wise implícito a subject-wise estricto? ¿Existe evidencia de fuga de información en algún diseño preliminar?
7. ¿Los intervalos de confianza de dos modelos se superponen? ¿Eso cambia su conclusión sobre cuál es realmente mejor?
8. ¿McNemar o la comparación de AUC apoyan una diferencia significativa o la mejora observada es solo marginal?
9. ¿Qué features resultaron más importantes según RF/boosting? ¿Tienen sentido fisiológico o solo parecen estadísticamente útiles?
10. ¿Cómo afecta el ruido, la presencia de artefactos o el cambio de base de datos al desempeño del modelo?
11. ¿SVM superó o no a RF/boosting? Explique la razón en términos de separación no lineal, tamaño del conjunto y estabilidad.

12. ¿Qué baseline publicado es el más comparable con su experimento y en qué aspectos la comparación todavía no es totalmente justa?
13. Si tuviera que desplegar el sistema en un escenario real con un EEG simple, ¿qué modelo elegiría y por qué?

Uso responsable de herramientas de IA

- Se permite usar IA para explorar papers, resumir literatura, generar código y depurar errores.
- Todo resultado generado con IA debe ser verificado por el estudiante antes de incluirlo en el informe o en el código final.
- No se permite inventar referencias, métricas, resultados ni experimentos que no fueron ejecutados.
- El informe debe indicar brevemente qué herramientas de IA se usaron y para qué tareas.
- Debe conservar prompts o notas de trabajo en un apéndice breve o bitácora técnica.

El valor académico del proyecto está en el diseño experimental, la reproducibilidad y el análisis crítico, no mostrar texto o código sin comprensión

Requisitos de implementación y reproducibilidad

- Se debe implementar el código pensando en que va a hacer reproducible. OBLIGATORIO: entorno de Desarrollo usando Docker para entornos reproducibles.
- Todo resultado debe guardarse en formato CSV; toda figura final debe guardarse en PNG.
- El proyecto debe registrar hiperparámetros, seeds, tiempos de entrenamiento y particiones usadas.
- Se debe incluir un archivo *.txt con scripts ejemplos de ejecución.
- El README.md debe explicar dependencias, estructura de carpetas, datasets y pasos para reproducir.

Entregables

Codificación con Agentes: Use el agente que mejor se adapte a usted: Cursor, Claude,Codex, GitHub Copilot

Deberá entregar lo siguiente:

1. Informe final en PDF.
2. Archivo con scripts de ejemplos de ejecución.
3. Código comprimido en .zip. (Deberá usar Docker para profesor reproduzca su código)
4. README.md con librerías, datasets, pasos de reproducción y notas de uso.

Rúbrica de evaluación

Criterio	Descriptor	Puntos
Comparaciones (Baselines)	Identifica modelos baseline publicados sobre los mismos datasets o sobre variantes muy cercanas. Explica por qué el baseline es comparable, qué protocolo empleó y métricas reportadas	20
Diseño experimental	Subject-wise, cross-dataset bien ejecutados.	10
Resultados y metricas	CSV/PNG claros, tablas legibles, figuras comparativas y discusión consistente. Métricas completas, pruebas estadísticas cuando procedan.	10
Análisis crítico	Responde con profundidad las preguntas de análisis; interpreta errores y generalización.	30
Propuesta de mejora	Método nuevo bien argumentado, factible y conectado con los resultados.	10
Reproducibilidad y documentación	README, reproducir.txt, organización del código y entregables completos.	20
BONO	Implementación de la Propuesta de mejora	Hasta un máximo de 20

Apéndices

A. Datos de sueño

En este proyecto, utiliza conjunto de datos se sueño el cual comprende grabaciones sueño de sujetos (ver Tabla 2.1). Los datos del sueño consisten en series de tiempo, donde el eje horizontal representa la variable tiempo y el eje vertical corresponde a los milivoltios capturados por el electrodo. Las muestras tienen 3000 columnas de datos(atributos) que corresponde a milivoltios capturados en un tiempo de 30 segundos. Las clases del conjunto de datos son 5 y representan a las cinco etapas del sueño, según las reglas de la Academia Americana de Medicina del Sueño (AASM), la cuales son descritas a continuación en la Tabla-2.2

Tabla-2.2: Etapas del Sueño

N	Etapa	Descripción	Código
1	W	Despierto, Predominan (más del 50%) las ondas **Alfa**	0
2	N1 (1-5%)	Adormecimiento. Transición entre la vigilia y el sueño. Ondas Alfa y Theta de baja amplitud.	1
3	N2 (45-55%)	Sueño ligero. Ondas **Theta.** Aparecen ráfagas cortas de actividad cerebral rápida y complejos K (ondas grandes y lentas)	2
4	N3 (15-25%)	Sueño profundo. Ondas **Delta (**lentas y de gran amplitud**)**	3
5	REM (20-25%)	movimientos oculares rápidos. Caracterizada por una alta actividad cerebral, similar a la vigilia. Ondas **Beta y Theta** rápidas y de bajo voltaje. Es la etapa donde ocurren los sueños.	4

El Ciclo del Sueño:
Estas etapas no ocurren una sola vez. Se suceden en ciclos que duran aproximadamente **90 a 120 minutos**. Un ciclo típico suele seguir el patrón:
N1 -> N2 -> N3 -> N2 -> REM
A lo largo de la noche, se repiten entre 4 y 6 ciclos. La composición de cada ciclo varía:

- **Primera mitad de la noche:** Predomina el sueño profundo (N3). Los periodos de REM son más cortos.
- **Segunda mitad de la noche:** El sueño N3 disminuye o desaparece, mientras que los periodos de REM se hacen más largos y frecuentes. El sueño N2 sigue siendo predominante.

B. Breve Comentarios sobre los modelo ML

Dentro de la literatura reciente, los modelos tradicionales que mejor han resistido la variabilidad del EEG monocanal son los ensambles de árboles (Random Forest, AdaBoost/XGBoost o RF híbrido) cuando se combinan con preprocesamiento de atributos y manejo explícito del desbalance. Las SVM siguen siendo competitivas, sobre todo en estructuras en cascada o con selección cuidadosa de atributos. Los HMM rara vez son la mejor opción como clasificador aislado, pero mejoran la consistencia temporal cuando se usan como modeladores de transiciones o como etapa de corrección secuencial.

Limitación común

• Generalización frágil entre bases o cohortes.

• N1 sigue siendo la clase más difícil.

• Fuerte dependencia de datasets públicos y, con frecuencia, sanos.

• Poco control explícito del ruido clínico y del cambio de dominio

Qué no se ha resuelto

• Un baseline clásico que mantenga alto desempeño en subject-wise y cross-dataset a la vez.
• Reconocer N1 con estabilidad usando solo EEG monocanal.
• Transferir modelos entrenados en bases públicas a poblaciones con apnea o entornos reales.
• Comparaciones totalmente justas bajo protocolos idénticos

C. Referencias a tomar en cuenta (formato tipo IEEE)

[1] M. Ghimatgar et al., “An automatic single-channel EEG-based sleep stage scoring method based on hidden Markov Model,” Journal of Neuroscience Methods, 2019.

[2] M. Ravan, “A machine learning approach using EEG signals to measure sleep quality,” AIMS Electronics and Electrical Engineering, 2019.

[3] I. Rechichi et al., “Single-channel EEG classification of sleep stages based on REM microstructure,” 2021.

[4] Y. Li et al., “Fast Sleep Stage Classification Using Cascaded Support Vector Machines with Single-Channel EEG Signals,” Sensors, 2022.

[5] Y. Gao et al., “Automatic sleep staging based on power spectral density and random forest,” 2023.

[6] S. Satapathy et al., “Machine learning-empowered sleep staging classification using multi-modality signals,” BMC Medical Informatics and Decision Making, 2024.

[7] J. Wang et al., “Research on Sleep Staging Based on Support Vector Machine and Extreme Gradient Boosting Algorithm,” 2024.

[8] X. Chen et al., “Single-Channel Sleep EEG Classification Method Based on LSTM and Hidden Markov Model,” 2024.

[9] E. Pouliou et al., “A New Approach for Sleep Stage Identification Combining Hidden Markov Models and EEG Signal Processing,” Journal of Medical and Biological Engineering, 2025.

[10] C. Xu et al., “An Effective and Interpretable Sleep Stage Classification Approach Using Multi-Domain Electroencephalogram and Electrooculogram Features,” Bioengineering, 2025.

[11] Heliyon review, “Machine and deep learning methods for sleep stage classification,” 2025.

[12] Review article, “A review of automated sleep stage based on EEG signals,” 2024.